AI-etikk og Regulering

BMED365: Momentliste A01–A09

BMED365

Vår 2027

Oversikt

1. Bioetikk og AI
2. EU AI Act
3. Ansvar og rettferdighet

A01: Diskutere de fire bioetiske prinsippene i AI-kontekst

Beauchamp & Childress' fire prinsipper:

1. **Autonomi** (Respekt for selvbestemmelse)
   - Informert samtykke til AI-bruk
   - Rett til å vite om AI er involvert
   - Mulighet til å velge bort AI-beslutninger
2. **Velgjørenhet** (Gjøre godt)
   - AI skal forbedre pasientutfall
   - Validert og effektiv
   - Tilgjengelig for alle
3. **Ikke-skade** (Primum non nocere)
   - Unngå skade fra feil prediksjoner
   - Minimere bias og diskriminering
   - Sikkerhetstesting før klinisk bruk
4. **Rettferdighet** (Rettferdig fordeling)
   - Lik tilgang til AI-forbedret helse
   - Unngå systematisk diskriminering
   - Representativ treningsdata

Utfordring

Prinsippene kan komme i konflikt – f.eks. effektivitet (velgjørenhet) vs. personvern (autonomi)

A02: Identifisere typer bias i medisinske AI-systemer

Bias = systematisk skjevhet som fører til urettferdige utfall

Kilder til bias:

1. **Historisk bias:** Treningsdata reflekterer historisk urettferdighet
   - Eksempel: Underrepresentasjon av minoriteter i kliniske studier
2. **Representasjonsbias:** Skjev pasientpopulasjon i treningsdata
   - Eksempel: Modell trent på kun hvite pasienter
3. **Målbias:** Feil proxy-variabler
   - Eksempel: Bruk av helsekostnader som mål på sykdom (korrelerer med rase)
4. **Evalueringsbias:** Testdata er ikke representativ
5. **Aggregeringsbias:** En modell for alle, ignorerer subgrupper

Konsekvens

Bias kan føre til at AI-systemer gir dårligere helsehjelp til allerede marginaliserte grupper.

A03: Forklare personvernhensyn ved bruk av LLM

Personvernutfordringer med LLM:

Datalekkasje til tredjepart:

- Input sendes til LLM-leverandør
- Potensielt brukt til retraining
- Lagres på utenlandske servere

Memorisering:

- LLM kan ha "lært" persondata
- Kan generere sensitiv info i output

Identifikasjon:

- Re-identifisering fra tilsynelatende anonyme data
- Prompt kan avsløre kontekst

Tiltak:

- Aldri del pasientidentifiserbar info med offentlige LLM
- Bruk lokale/sikre løsninger (chat.uib.no)
- Anonymisering og pseudonymisering

Viktig regel

Aldri legg inn pasientdata i ChatGPT, Claude eller andre offentlige LLM!

A04: Beskrive hovedtrekkene i EU AI Act

EU AI Act (vedtatt 2024):

- Verdens første omfattende AI-regulering
- Risikobasert tilnærming
- Gjelder alle som tilbyr eller bruker AI i EU

Hovedprinsipper:

1. **Risikoklassifisering:** AI-systemer kategoriseres etter risiko
2. **Krav proporsjonale med risiko:** Høyere risiko = strengere krav
3. **Transparens:** Brukere må informeres om AI-bruk
4. **Menneskers tilsyn:** Human-in-the-loop for høyrisiko
5. **Dokumentasjon:** Teknisk dokumentasjon og logging
6. **CE-merking:** Samsvarsvurdering før lansering

Tidslinje

Gradvis innføring 2024–2027. Høyrisiko AI-krav gjelder fra 2026.

A05: Forklare risikoklassifisering i EU AI Act

Fire risikonivåer:

1. **Uakseptabel risiko** (FORBUDT)
   - Social scoring, manipulasjon, real-time ansiktsgjenkjenning
2. **Høy risiko** (STRENGE KRAV)
   - Medisinsk utstyr og diagnostikk
   - Kritisk infrastruktur, utdanning, arbeidsmarked
   - Krever risikovurdering, dokumentasjon, menneskelig tilsyn
3. **Begrenset risiko** (TRANSPARENSKRAV)
   - Chatbots, deepfakes
   - Må informere om at det er AI
4. **Minimal risiko** (INGEN SPESIFIKKE KRAV)
   - Spamfiltre, spill-AI
   - Frivillige etiske retningslinjer

Medisinsk AI

De fleste medisinske AI-systemer vil klassifiseres som **høy risiko**.

A06: Diskutere krav til høyrisiko AI i helsevesenet

Krav til høyrisiko AI-systemer:

Før lansering:

- Risikovurdering og -håndtering
- Høy datakvalitet og representativitet
- Teknisk dokumentasjon
- Transparens og brukerveiledning
- Cybersikkerhet
- Samsvarsvurdering (CE-merking)

Under bruk:

- Automatisk logging
- Menneskelig tilsyn
- Post-market overvåking
- Hendelsesrapportering
- Periodisk revurdering

Spesifikt for medisinsk AI:

- Koordineres med MDR (Medical Devices Regulation)
- Klinisk evidens og validering kreves
- Krav om forklarbarhet og robusthet

A07: Reflektere over ansvarsfordeling når AI feiler

Hvem er ansvarlig når AI tar feil?

Potensielle ansvarlige:

- **AI-utvikleren:** Design, trening, validering
- **Helseinstitusjonen:** Innkjøp, implementering, opplæring
- **Klinikeren:** Bruker AI, tar endelig beslutning
- **Pasienten:** Samtykker til AI-bruk?

Problemstillinger:

- AI som "black box" – vanskelig å forstå feil
- Delt ansvar → utvannet ansvar?
- Automatiseringsbias – overtillit til AI

Rettslig utvikling:

- AI Liability Directive (EU)
- Produktansvar utvidet til AI
- Bevisbyrde kan legges på AI-leverandør

Hovedprinsipp

Kliniker har fortsatt det endelige ansvaret – AI er et **verktøy**, ikke en erstatning.

A08: Kjenne til GDPR-relevante aspekter ved AI

GDPR og AI i helse:

Nøkkelprinsipper:

- **Lovlig grunnlag:** Samtykke, nødvendighet, berettiget interesse
- **Formålsbegrensning:** Data kun til oppgitt formål
- **Dataminimering:** Kun nødvendige data
- **Lagringsbegrensning:** Ikke lagre lenger enn nødvendig

Spesielle bestemmelser:

- **Art. 22:** Rett til å ikke bli utsatt for automatiserte beslutninger
- **Art. 9:** Helsedata er "spesiell kategori" – ekstra beskyttet
- **Art. 35:** DPIA (personvernkonsekvensvurdering) for høyrisiko

Viktig

Pasientdata brukt til AI-trening/bruk krever lovlig grunnlag og ofte DPIA.

A09: Diskutere algoritmisk rettferdighet (fairness)

Fairness i ML: Ingen universell definisjon

Ulike rettferdighetsdefinisjoner:

1. **Demografisk paritet:** Lik andel positive prediksjoner per gruppe
2. **Equalised odds:** Lik TPR og FPR per gruppe
3. **Calibration:** Konfidensscorer betyr det samme for alle grupper
4. **Individual fairness:** Like individer behandles likt

Problemet:

- Disse definisjonene er ofte **matematisk inkompatible**
- Valg av definisjon er en **verdiladet** beslutning
- "Fair" i én forstand kan være "unfair" i en annen

Medisinsk eksempel

Skal en risikomodell gi lik score til en 30-åring og 70-åring med samme symptomer? Alder er en risikofaktor – er det diskriminering?

Oppsummering: AI-etikk og Regulering

Bioetikk og bias:

- A01: Fire bioetiske prinsipper i AI-kontekst
- A02: Typer bias – historisk, representasjons-, mål-, evaluerings-
- A03: Personvernhensyn ved LLM

EU AI Act:

- A04–A06: Risikobasert tilnærming, høyrisiko-krav for medisin

Ansvar og rettferdighet:

- A07: Ansvarsfordeling – komplekst, kliniker har endelig ansvar
- A08: GDPR – spesialbeskyttelse for helsedata
- A09: Algoritmisk rettferdighet – ingen enkel løsning

Praktisk i Lab 3

Diskuter etiske implikasjoner av LLM, bias-analyse, og personvernhensyn.