Generativ AI og Store Språkmodeller

BMED365: Momentliste G01–G20

BMED365

Vår 2027

Oversikt

1. Introduksjon til Generativ AI
2. Transformer-arkitekturen
3. LLM-grunnleggende
4. Prompt Engineering
5. Context Engineering
6. Utfordringer med LLM
7. Modeller og avanserte konsepter

G01: Definere generativ AI og skille fra diskriminativ AI

Diskriminativ AI:

- Lærer å **klassifisere** eller skille mellom kategorier
- Modellerer $P(y|x)$ – sannsynlighet for klasse y gitt input x
- Eksempler: "Er dette kreft?", "Hvilken sykdom?"
- CNN for bildeklassifisering

Generativ AI:

- Lærer å **skape** nytt innhold
- Modellerer $P(x)$ eller $P(x|y)$ – datafordelingen selv
- Eksempler: Tekst, bilder, kode, musikk
- LLM, diffusjonsmodeller

Nøkkelforskjell

Diskriminativ: Input $x \rightarrow$ Kategori/Label y | **Generativ:** Prompt $\rightarrow$ Nytt innhold

Medisinsk anvendelse

Generativ AI: Oppsummere journaler, generere rapporter, svare på spørsmål, syntetisere treningsdata

G02: Forklare self-attention-mekanismen på et konseptuelt nivå

Self-attention: "Hva er relevant for hva?"

Intuisjon:

- For hvert ord: Se på **alle** andre ord i setningen
- Beregn en **vektet sum** basert på relevans
- Fanger opp avhengigheter over lange avstander

Eksempel:

*"Pasienten tok **medisinen**, og **den** hjalp mot smertene."*

- Self-attention kobler "den" til "medisinen" (ikke "smertene")

Query, Key, Value (QKV)

Hvert token genererer tre vektorer:
Query "Hva leter jeg etter?" | **Key** "Hva kan jeg tilby?" | **Value** "Hva er innholdet mitt?"

G03: Beskrive transformer-arkitekturen (encoder-decoder)

Transformer-arkitekturen (Vaswani et al., 2017):

Encoder:

- Prosesserer input-sekvens
- Bygger kontekstrik representasjon
- Brukes i: BERT, embeddings

Decoder:

- Genererer output sekvensielt
- Bruker maskert self-attention
- Brukes i: GPT, Claude, Gemini

Full encoder-decoder:

- Oversettelse, oppsummering
- T5, Flan-T5

Nøkkelkomponenter:

1. Multi-head self-attention
2. Feed-forward nettverk
3. Layer normalization
4. Residual connections
5. Positional encoding

GPT = "Decoder-only"

Store språkmodeller (LLM) bruker typisk kun decoder-delen for tekstgenerering.

G04: Forklare hva tokens er og hvordan tokenisering fungerer

Tokens = tekstens "atomer"

- LLM-er leser ikke bokstaver eller ord – de leser **tokens**
- Token $\approx$ delord, ca. 4 tegn per token (for engelsk/norsk)

Tokenisering – eksempel:

$$\texttt{``Pasienten har diabetes''} \rightarrow [\texttt{``Pas''}, \texttt{``ient''}, \texttt{``en''}, \texttt{`` har''}, \texttt{`` diab''}, \texttt{``etes''}]$$

BPE og språkforskjeller:

- Bygger vokabular iterativt
- GPT-4: ca. 100 000 tokens
- **Kinesisk:** Hvert tegn $\approx$ 1–2 tokens
- Forenklet/tradisjonell: Ulike tokens

Viktig å vite:

- Lange/sjeldne ord = flere tokens
- Påvirker kostnad og hastighet
- `tiktoken` (OpenAI) for telling
- Ulike modeller = ulike tokenizers

Hvorfor tokens?

Mer effektivt enn bokstaver (for kort) eller hele ord (vokabular for stort).

G05: Forstå konseptet kontekstvindu (context window)

Kontekstvindu = modellens "arbeidsminne"

- Maksimalt antall tokens modellen kan "se" samtidig
- Inkluderer både **input** (prompt) og **output** (svar)

Eksempler på kontekstvinduer:

Modell	Kontekst	≈ Sider
GPT-4o	128K	∼150 sider
GPT-5	256K+	∼300 sider
Claude Opus 4.5	200K	∼250 sider
Gemini 3 Pro	2M+	Hele bøker!

Input vs. output:

- **Input-kontekst:** Hvor mye modellen kan lese
- **Output-kontekst:** Hvor langt svar den kan gi
- Output ofte mindre (4K–32K tokens)

Begrensninger

For lange tekster må kuttes. Modellen "glemmer" utenfor vinduet. Større vindu = dyrere/tregere.

G06: Forklare hva temperatur betyr i tekstgenerering

Temperatur = kontroll over "kreativitet"

Teknisk:

- Skalerer logits før softmax: $p_i = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}$
- **Effekt:** Lav $T \rightarrow$ skarpere fordeling (høyeste logit dominerer); Høy $T \rightarrow$ flatere fordeling (mer tilfeldighet)

Lav temperatur (0.0–0.3):

- Mer deterministisk
- Velger mest sannsynlige tokens
- Konsistent, "trygt"
- ✔ Medisinsk info, fakta

Høy temperatur (0.7–1.0+):

- Mer tilfeldig/kreativ
- Flere overraskende valg
- Mer variasjon
- ✔ Kreativ skriving, brainstorming

Anbefaling for medisin

Bruk **lav temperatur** (0.0–0.3) for faktabaserte oppgaver. Høyere temperatur øker risiko for hallusinering.

G07: Anvende zero-shot prompting

Zero-shot = ingen eksempler – be modellen løse oppgaven **uten å vise eksempler**

Eksempler på zero-shot prompts:

Zero-shot prompts

1. `Klassifiser symptom som akutt/kronisk: "Hodepine i 3 mnd"`
2. `Oppsummer journalnotatet i 3 setninger.`
3. `Oversett til pasientvennlig språk: "Bilateral pneumoni"`
4. `Ekstraher alle medikamenter fra denne teksten.`
5. `Er denne lab-verdien unormal? Hb 8.2 g/dL`

Når fungerer zero-shot?

- Modellen har sett lignende oppgaver
- Oppgaven er tydelig definert

Begrensninger

For spesialiserte oppgaver kan zero-shot gi dårlige resultater. Da trengs **few-shot**.

G08: Anvende few-shot prompting

Few-shot = noen eksempler

- Gi modellen **2–5 eksempler** på ønsket input-output
- Modellen lærer mønsteret "in-context"

Few-shot prompt

```
Klassifiser symptomvarighet:
Symptom: "Brystsmerter i 30 minutter" → Akutt
Symptom: "Ryggsmerter i 2 år" → Kronisk
Symptom: "Feber siden i går" → Akutt
--
Symptom: "Hodepine i 3 måneder" →
```

Tips for effektiv few-shot:

- Velg **representative** eksempler
- Vis **variasjonen** i mulige outputs
- Hold eksemplene **konsistente** i format
- Start med 3–5 eksempler, juster ved behov

G09: Anvende Chain-of-Thought (CoT) prompting

Chain-of-Thought = vis resonnementet

- Be modellen **tenke steg-for-steg**
- Forbedrer ytelse på komplekse resonneringsoppgaver

Uten CoT

```
Bør pasienten henvises?
→ "Ja"
```

Med CoT

```
Tenk steg-for-steg:
1. Symptomer: X, Y, Z
2. Alvorlighetsgrad: Moderat
→ Konklusjon: Bør henvises
```

Varianter:

- **Zero-shot CoT:** "Let's think step by step"
- **Few-shot CoT:** Vis eksempler med resonnement

Innebygd CoT i nyere LLM-er

ChatGPT o1/o3 (Thinking), Claude Opus 4.5 (Extended Thinking), Gemini 3 (Deep Think) har CoT innebygd.

G10: Beskrive god praksis for systemprompts

Systemprompt = instruksjon som setter kontekst

Elementer i et godt systemprompt:

1. **Rolle:** "Du er en medisinsk assistent..."
2. **Kontekst:** "Brukeren er helsepersonell..."
3. **Oppførsel:** "Svar konsist og presist..."
4. **Begrensninger:** "Ikke gi diagnoser..."
5. **Format:** "Svar på norsk, bruk punktlister..."

Eksempel på systemprompt

```
Du er en medisinsk AI-assistent for helsepersonell. Svar på norsk. Vær presis og evidensbasert. Henvis til kilder når mulig. Gi aldri definitive diagnoser - foreslå differensialdiagnoser. Ved usikkerhet, si fra.
```

Tips

Test og iterer på systemprompts! Små endringer kan gi stor effekt.

G15: Fra Prompt Engineering til Context Engineering

Prompt Engineering vs. Context Engineering:

- **Prompt engineering:** Fokus på å utforme gode spørsmål
- **Context engineering:** Designe *hele kontekstvinduet* strategisk

Komponenter i context engineering:

Komponent	Beskrivelse	Medisinsk eksempel
System prompt	Rolle og instruksjoner	"Klinisk beslutningsstøtte"
Bruker-prompt	Spesifikt spørsmål	"Vurder pasientens symptomer"
Verktøy	Tilgjengelige handlinger	Lab-søk, ICD-10, Felleskatalogen
RAG-kontekst	Hentet informasjon	Retningslinjer, journal, artikler
Samtalehistorikk	Tidligere dialog	Tidligere spørsmål og svar
Strukturerte data	Formattert info	JSON med vitale tegn

Hvorfor viktig i medisin?

Rik kontekst → sikrere, mer relevante og personaliserte svar

G16–G17: Modellspesifikke prompting-teknikker

Tre ledende LLM-leverandører med ulike styrker:

GPT-5.2 (OpenAI):

- Sterkest på strukturert output
- Beste verktøyintegrasjon
- God instruksjonsetterlevelse

Godt egnet for:

- JSON-ekstraksjon
- API-integrasjoner
- Agentiske systemer

Claude Opus 4.5:

- 200K tokens kontekst
- Nyansert resonnering
- Constitutional AI

Godt egnet for:

- Etiske dilemmaer
- Lang journalanalyse
- Pasientkommunikasjon

Gemini 3 (Google):

- Multimodal (bilde+tekst)
- Sanntids websøk
- Vitenskapelig styrke

Godt egnet for:

- Bildeanalyse
- Litteratursøk
- Beregninger

Lab 3 Notebook 04

Inneholder detaljerte prompting-guider for hver modell + sammenligningseksperimenter

G18: Håndtere usikkerhet og hallusinasjonsrisiko

Prompt-mønster for medisinsk usikkerhetshåndtering:

Anti-hallusinasjons prompt (GPT-5.2 stil)

```
<usikkerhet_og_tvetydighet>
- Ved tvetydige symptomer: Presenter differensialdiagnoser med sannsynlighet
- Oppgi tydelig kunnskapens begrensninger og dato for oppdatering
- Henvis alltid til gjeldende retningslinjer og klinisk vurdering
- Ved usikkerhet: Eskalér til høyere hastegrad
</usikkerhet_og_tvetydighet>
```

Selvsjekk for høyrisiko-oppgaver:

1. Skann eget svar for usagte antakelser
2. Verifiser at tall og påstander er forankret i kontekst
3. Unngå for sterk språkbruk ("alltid", "garantert")
4. Kvalifiser konklusjoner med usikkerhetsgrad

Huskeregel

AI = beslutningsstøtte, **ikke** beslutningstaker. Alltid klinisk validering!

G19–G20: Strukturert ekstraksjon og modellsammenligning

G19: Strukturert ekstraksjon:

JSON-skjema for epikrise

```
{
  diagnose": {
    tekst": string,
    "icd10": string | null
  },
  legemidler": [{
    navn": string,
    dose": string
  }]
}
```

Viktige regler:

- Bruk `null` for manglende felt
- Krev kildereferanser
- Verifiser mot originaldokument

G20: Beslutningsmatrise:

Oppgave	Modell
Strukturert output	GPT-5.2
Etiske vurderinger	Claude
Bildeanalyse	Gemini
Lang kontekst	Claude
Sanntidssøk	Gemini
Verktøy/API	GPT-5.2

Praktisk tips:

1. Test samme prompt på 2–3 modeller
2. Sammenlign mot evalueringskriterier
3. Velg modell basert på oppgave
4. Dokumenter valg for etterprøvbarhet

G11: Definere hallusinering og dens implikasjoner

Hallusinering = modellen "finner på" feil informasjon

- LLM-er genererer tekst som *høres* riktig ut, men er *faktisk feil*
- Også kalt *konfabulering* – begge termer brukes i litteraturen

Typer hallusinasjoner:

- **Faktiske feil:** Feil statistikk, datoer, navn
- **Oppdiktede kilder:** Referanser som ikke eksisterer
- **Logiske feil:** Inkonsistente resonnementer

Utvikling:

- Nyere modeller hallusinerer *mindre*
- Kan *ikke* elimineres helt
- RAG og CoT reduserer risiko

Implikasjoner i medisin

Feil dosering kan være livstruende. **Alltid verifiser** mot pålitelige kilder! LLM = beslutningsstøtte, **ikke** erstatning for fagkunnskap.

G12: Kjenne til GPT-5, Claude, Gemini og deres anvendelser

Modell	Utvikler	Styrker	Anvendelse
GPT-5/o3	OpenAI	Multimodal, reasoning	ChatGPT, Copilot
Claude 4	Anthropic	200K kontekst, "trygg"	Dokumentanalyse
Gemini 3	Google	Integrert i Colab	Kodehjelp, søk
Llama 4	Meta	Open source, lokalt	Forskning

Lokale modeller:

- Ollama, LM Studio
- Destillering: Liten modell lærer fra stor
- Kvantisering: Redusert presisjon (16→4 bit)
- GDPR-vennlig, offline

chat.uib.no

Styrker: GDPR-ok, ingen datalagring, gratis for UiB
Svakheter: Eldre modell, begrenset kontekst, ikke multimodal

G13: Forklare konseptet grunnmodell (foundation model)

Foundation model = pretrent på enorme datamengder

- Trent på terabytes av tekst/bilder uten spesifikk oppgave
- Kan tilpasses (*finetuned*) til mange forskjellige oppgaver
- Koster millioner å trene fra scratch

Karakteristikker:

1. **Stor skala:** Milliarder av parametre
2. **Selvveiledet læring:** Ingen labels nødvendig
3. **Emergente egenskaper:** Evner som "dukker opp" ved skala
4. **Tilpasningsbar:** Finetuning, prompting, RAG

Eksempler på foundation models (2025)

Tekst: GPT-5, Claude 4, Llama 4 | **Bilder:** DALL-E 3, Stable Diffusion 3 | **Multimodal:** Gemini 3, Sora

G14: Beskrive RAG (Retrieval-Augmented Generation)

RAG = koble LLM til ekstern kunnskapsbase

Problemet RAG løser:

- LLM har "frossen" kunnskap
- Kan hallusinere fakta
- Mangler domene-spesifikk info

Hvordan RAG fungerer:

1. **Spørring:** Bruker stiller spørsmål
2. **Retrieval:** Hent dokumenter
3. **Augmentation:** Legg til prompt
4. **Generation:** LLM svarer

Medisinsk anvendelse

- Koble LLM til retningslinjer, Felleskatalogen, UpToDate
- Svare basert på pasientjournal (med tilganger)
- Reduserer hallusinering ved å forankre svar i kilder
- Klinisk beslutningsstøtte med oppdatert evidens
- Søk i institusjons-spesifikke prosedyrer og protokoller

Oppsummering: Generativ AI og LLM

Grunnleggende:

- G01: Generativ vs. diskriminativ AI
- G02–G03: Self-attention og transformer-arkitektur
- G04–G06: Tokens, kontekstvindu, temperatur

Prompt og context engineering:

- G07–G10: Zero-shot, few-shot, CoT, systemprompts
- G15–G17: Context engineering, modellspesifikke teknikker
- G18–G20: Usikkerhetshåndtering, strukturert ekstraksjon

Utfordringer og avansert:

- G11: Hallusinering – kritisk i medisinsk kontekst
- G12–G14: Modeller (GPT-5.2, Claude, Gemini), RAG

Lab 3 Notebook 04

Detaljerte prompting-guider for GPT-5.2, Claude Opus 4.5 og Gemini 3 med sammenligningseksperimenter.