Maskinlæring – Grunnleggende konsepter

ELMED219: Momentliste M01–M10

ELMED219

Vår 2027

Oversikt

1. **Hva er maskinlæring?**
   - M01: Definisjon og skille fra tradisjonell programmering
   - M02: Supervised vs. Unsupervised læring
   - M03: Features og Labels
2. **Validering og modelltyper**
   - M04–M05: Trenings-/testsett, overtilpasning/undertilpasning
   - M06–M07: Bias-Variance trade-off, K-fold kryssvalidering
   - M08–M10: Baseline, klassifisering vs. regresjon, enkle modeller

M01: Definere maskinlæring og skille fra tradisjonell programmering

Tradisjonell programmering:

- Eksplisitte regler definert av programmerer
- `if-else` logikk, deterministisk
- Input + Regler → Output
- Krever full domenekunnskap på forhånd

Maskinlæring:

- Lærer regler fra data automatisk
- Mønstergjenkjenning, statistisk
- Input + Output → Regler (modell)
- Skalerer med datamengde

Definisjon (Tom Mitchell, 1997)

*"A computer program is said to **learn from experience** E with respect to some task T and some performance measure P, if its performance on T, as measured by P, improves with experience E."*

Definisjon (Tom Mitchell, 1997) – på norsk

*"Et dataprogram sies å **lære av erfaring** E med hensyn til en oppgave T og et ytelsesmål P, dersom dets ytelse på T, målt ved P, forbedres med erfaring E."*

M02: Supervised vs. Unsupervised læring

Supervised (veiledet) læring:

- Data har **labels** (fasit/merkelapper)
- Modellen lærer input→output-mapping
- Typer: Klassifisering, regresjon
- Medisinsk: Diagnostisering, prognose
- Krever manuell annotering av data

Unsupervised (ikke-veiledet) læring:

- Data **uten** labels
- Finner skjulte mønstre/strukturer
- Typer: Klynging, dimensjonsreduksjon
- Medisinsk: Pasient-subgrupper
- Ingen fasit – utforskende analyse

Semi-supervised (delvis veiledet) – prinsipper og anvendelser

Kombinerer få merkede eksempler med mange umerkede. Nyttig når annotering er dyrt/tidkrevende.

Prinsipper: *Smoothness* – nærliggende datapunkter har ofte samme label. *Tabulært:* pasienter med like lab-verdier har ofte samme diagnose. *Bilde:* MR-snitt med lignende pikselintensiteter viser lignende patologi. *Cluster* – data grupperer seg naturlig; punkter i samme klynge tilhører ofte samme klasse. *Tabulært:* pasienter med diabetes klynger seg i feature-rommet. *Bilde:* hjerne-MR av friske vs. Alzheimer danner separate klynger. *Manifold* – et 256×256 bilde $= 65536$ piksler, men meningsfull variasjon bestemmes av få faktorer (anatomi, patologi). Bildene "fyller" ikke hele rommet, men ligger på en lavdim. flate.

Anvendelser: Medisinsk bildesegmentering, tekstklassifisering, talegjenkjenning, legemiddeloppdagelse, genomikk.

M03: Features (input) og Labels (output)

Definisjoner

- **Features** (X): Inputvariabler / egenskaper / kjennetegn som beskriver dataene
- **Labels** (y): Målvariabel / det vi ønsker å predikere (fasit)

Eksempel – Hjertesykdomsprediksjon (tabulære data):

Alder	Kolesterol	Blodtrykk	BMI	Sykdom?
55	240	140	28	Ja
32	180	120	23	Nei
67	210	155	31	Ja

Features X (kolonner = variabler) **Label** y

Rader = observasjoner/pasienter, Kolonner = variabler → **Matrise**

M04: Hvorfor treningssett og testsett?

Problemet: Hvordan vet vi om modellen generaliserer til nye data?

Løsningen: Data-splitting

1. Del datasettet i to (eller tre) deler
2. **Treningssett** (∼70–80%): Tren modellen
3. **Testsett** (∼20–30%): Evaluer på usett data
4. (Valideringssett: Tuning av hyperparametre)



Viktig

Modellen skal **aldri** se testdataene under trening!

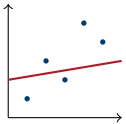
scikit-learn

```
train_test_split(X, y, test_size=0.2)
```

M05: Overtilpasning (Overfitting) og Undertilpasning (Underfitting)

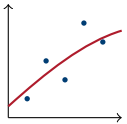
Undertilpasning:

- For enkel modell
- Høy bias
- Dårlig på trening og test



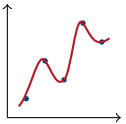
God tilpasning:

- Riktig kompleksitet
- Balanse
- Generaliserer godt



Overtilpasning:

- For kompleks modell
- Høy varians
- Lærer støy i dataene



Kjennetegn på overtilpasning

Stor forskjell mellom trenings- og test-ytelse (performance). **Ytelse** = mål på hvor godt modellen presterer (f.eks. accuracy, F1).

M06: Bias-Variance Trade-off

Totalt prediksjonsfeil:

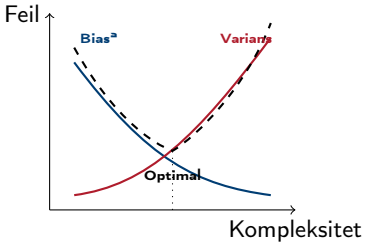
$$\text{MSE} = \underbrace{\text{Bias}^2}_{\text{systematisk feil}} + \underbrace{\text{Varians}}_{\text{tilfeldig feil}} + \underbrace{\sigma^2}_{\text{irreducible}}$$

Bias (systematisk feil):

- Feil pga. forenklet modell
- Høy bias → **undertilpasning**
- Modellen "misser" mønsteret

Varians (tilfeldig feil):

- Sensitiv for små endringer i data
- Høy varians → **overtilpasning**
- Modellen "husker" støy



Målet

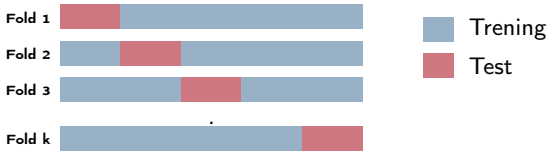
Finn balansen som minimerer **total feil** på nye data. σ^2 = støy i data (kan ikke reduseres).

M07: K-fold kryssvalidering

Problem: Ett enkelt train/test-split kan gi tilfeldige resultater

Løsning: K-fold Cross-Validation

1. Del data i k like store deler ("folds")
2. For hver fold: bruk den som test, resten som trening
3. Gjennomsnitt av alle k evalueringer



Fordeler: Mer robust estimat, bruker all data for både trening og testing

M08: Baseline-modell

Hva er en baseline?

En **enkel referansemodell** som vår ML-modell må slå for å være nyttig.

Eksempler på baselines:

- **Klassifisering:** Prediker alltid majoritetsklassen
  - Datasett med 90% friske, 10% syke → baseline accuracy = 90%
- **Regresjon:** Prediker alltid gjennomsnittsverdien
- **Tidsserie:** Bruk forrige verdi som prediksjon

Hvorfor viktig?

90% accuracy høres imponerende ut, men ikke hvis baseline er 90%! Viser om ML tilfører **faktisk verdi**. Avslører ubalanserte datasett.

M09: Klassifisering vs. Regresjon

Klassifisering:

- Predikerer **kategorier/klasser**
- Diskrete utfall
- Eksempler:
  - Syk / Frisk
  - Kreft type A / B / C

Evalueringsmetrikker:

- Accuracy, Precision, Recall
- F1-score, AUC-ROC

Regresjon:

- Predikerer **kontinuerlige verdier**
- Numeriske utfall
- Eksempler:
  - Blodtrykk
  - Medikamentdosering

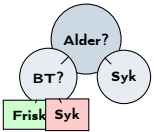
Evalueringsmetrikker:

- MSE, RMSE, MAE
- R^2 (forklart varians)

M10: Enkle ML-modeller

Beslutningstre:

- Serier av ja/nei-spørsmål
- Lett å tolke
- Kan overtilpasse



k-Nearest Neighbors:

- Finn k mest like eksempler
- Majoritetsvotering
- Enkel, men treg



Logistisk regresjon:

- Lineær grense
- Gir sannsynligheter
- Rask og tolkbar



Tips

Start alltid med enkle modeller før du prøver komplekse!

Oppsummering: M01–M10

Nøkkelkonsepter:

- ML lærer fra data
- Supervised / Unsupervised / Semi-supervised
- Features (X), Labels (y)
- Trening / test / validering
- Over-/undertilpasning

Beste praksis:

- Kryssvalidering
- Sammenlign med baseline
- Klassifisering $\neq$ Regresjon
- Start enkelt
- Bias-varians-balanse

Fremtid: ML + GenAI

- LLM-agenter for dataanalyse
- Multimodale modeller (tekst+bilde)
- RAG + kliniske retningslinjer
- Automatisert ML-pipeline
- Human-in-the-loop AI

Medisinsk relevans – ML-anvendelser i helse, medisin og bioteknologi

Diagnostikk: Bildediagnostikk (radiologi, patologi, oftalmologi, dermatologi), biomarkørdeteksjon, EKG/EEG-analyse.
Prognose: Overlevelse (OS), progresjonsfri overlevelse (PFS), reinnleggelse, mortalitetsrisiko, sykdomsprogresjon.
Terapi: Terapivalg, doseoptimalisering, behandlingsrespons, stråleplanlegging, kirurgisk navigasjon.
Legemiddel: Drugability, målidentifikasjon, ADMET-prediksjon, virtual screening, de novo molekyldesign.
Helsesystem: Ressursallokering, kapasitetsplanlegging, triagering, ventelisteoptimering, utbruddsdeteksjon.
Genomikk/biotek: Variantklassifisering, genekspresjon, proteinstruktur (AlphaFold), single-cell, CRISPR off-target.
Psykiatri/nevrologi: Stemningsanalyse, talemarkører, nevrodegenerasjon, anfallsprediksjon.
Folkehelse: Epidemiologisk modellering, vaksinestrategi, sosiale determinanter, helseøkonomi (QALY/DALY).

Human-in-the-loop: **Pasientbilde** → **ML: "mulig malign" (87%)** → **Radiolog vurderer** → **Bekrefter/avviser** → **Feedback** → **Modell forbedres**