# Maskinlæring – Grunnleggende konsepter

## BMED365: Momentliste M01–M10

BMED365

Vår 2027

# Oversikt

1. **Hva er maskinlæring?**
   - M01: Definisjon og skille fra tradisjonell programmering
   - M02: Supervised vs. Unsupervised læring
   - M03: Features og Labels
2. **Validering og modelltyper**
   - M04–M05: Trenings-/testsett, overtilpasning/undertilpasning
   - M06–M07: Bias-Variance trade-off, K-fold kryssvalidering
   - M08–M10: Baseline, klassifisering vs. regresjon, enkle modeller

# M01: Definere maskinlæring og skille fra tradisjonell programmering

**Tradisjonell programmering:**

- Eksplisitte regler definert av programmerer
- `if-else` logikk, deterministisk
- Input + Regler $\rightarrow$ Output
- Krever full domenekunnskap på forhånd

**Maskinlæring:**

- Lærer regler fra data automatisk
- Mønstergjenkjenning, statistisk
- Input + Output $\rightarrow$ Regler (modell)
- Skalerer med datamengde

**Definisjon (Tom Mitchell, 1997)**

*"A computer program is said to **learn from experience** E with respect to some task T and some performance measure P, if its performance on T, as measured by P, improves with experience E."*

**Definisjon (Tom Mitchell, 1997) – på norsk**

*"Et dataprogram sies å **lære av erfaring** E med hensyn til en oppgave T og et ytelsesmål P, dersom dets ytelse på T, målt ved P, forbedres med erfaring E."*

# M02: Supervised vs. Unsupervised læring

**Supervised (veiledet) læring:**

- Data har **labels** (fasit/merkelapper)
- Modellen lærer input→output-mapping
- Typer: Klassifisering, regresjon
- Medisinsk: Diagnostisering, prognose
- Krever manuell annotering av data

**Unsupervised (ikke-veiledet) læring:**

- Data **uten** labels
- Finner skjulte mønstre/strukturer
- Typer: Klynging, dimensjonsreduksjon
- Medisinsk: Pasient-subgrupper
- Ingen fasit – utforskende analyse

**Semi-supervised (delvis veiledet) – prinsipper og anvendelser**

Kombinerer få merkede eksempler med mange umerkede. Nyttig når annotering er dyrt/tidkrevende.

**Prinsipper:** *Smoothness* – nærliggende datapunkter har ofte samme label. *Tabulært:* pasienter med like lab-verdier har ofte samme diagnose. *Bilde:* MR-snitt med lignende pikselintensiteter viser lignende patologi. *Cluster* – data grupperer seg naturlig; punkter i samme klynge tilhører ofte samme klasse. *Tabulært:* pasienter med diabetes klynger seg i feature-rommet. *Bilde:* hjerne-MR av friske vs. Alzheimer danner separate klynger. *Manifold* – et $256 \times 256$ bilde $= 65536$ piksler, men meningsfull variasjon bestemmes av få faktorer (anatomi, patologi). Bildene "fyller" ikke hele rommet, men ligger på en lavdim. flate.

**Anvendelser:** Medisinsk bildesegmentering, tekstklassifisering, talegjenkjenning, legemiddeloppdagelse, genomikk.

# M03: Features (input) og Labels (output)

**Definisjoner**

- **Features** (X): Inputvariabler / egenskaper / kjennetegn som beskriver dataene
- **Labels** ($y$): Målvariabel / det vi ønsker å predikere (fasit)

**Eksempel – Hjertesykdomsprediksjon (tabulære data):**

| Alder | Kolesterol | Blodtrykk | BMI | Sykdom? |
|---|---|---|---|---|
| 55 | 240 | 140 | 28 | Ja |
| 32 | 180 | 120 | 23 | Nei |
| 67 | 210 | 155 | 31 | Ja |

**Features** X (kolonner = variabler) **Label** $y$

Rader = observasjoner/pasienter, Kolonner = variabler → **Matrise**

# M04: Hvorfor treningssett og testsett?

**Problemet:** Hvordan vet vi om modellen generaliserer til nye data?

**Løsningen: Data-splitting**

1. Del datasettet i to (eller tre) deler
2. **Treningssett** (∼70–80%): Tren modellen
3. **Testsett** (∼20–30%): Evaluer på usett data
4. (Valideringssett: Tuning av hyperparametre)




**Viktig**

Modellen skal **aldri** se testdataene under trening!

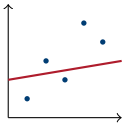
**scikit-learn**

```
train_test_split(X, y, test_size=0.2)
```

# M05: Overtilpasning (Overfitting) og Undertilpasning (Underfitting)

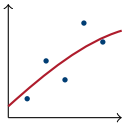
**Undertilpasning:**

- For enkel modell
- Høy bias
- Dårlig på trening og test



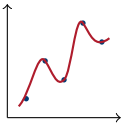
**God tilpasning:**

- Riktig kompleksitet
- Balanse
- Generaliserer godt



**Overtilpasning:**

- For kompleks modell
- Høy varians
- Lærer støy i dataene



**Kjennetegn på overtilpasning**

Stor forskjell mellom trenings- og test-ytelse (performance). **Ytelse** = mål på hvor godt modellen presterer (f.eks. accuracy, F1).

# M06: Bias-Variance Trade-off

**Totalt prediksjonsfeil:**

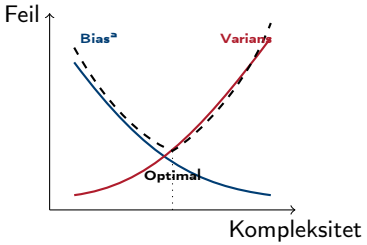
$$\text{MSE} = \underbrace{\text{Bias}^2}_{\text{systematisk feil}} + \underbrace{\text{Varians}}_{\text{tilfeldig feil}} + \underbrace{\sigma^2}_{\text{irreducible}}$$

**Bias (systematisk feil):**

- Feil pga. forenklet modell
- Høy bias → **undertilpasning**
- Modellen "misser" mønsteret

**Varians (tilfeldig feil):**

- Sensitiv for små endringer i data
- Høy varians → **overtilpasning**
- Modellen "husker" støy




**Målet**

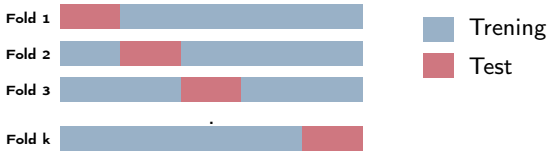
Finn balansen som minimerer **total feil** på nye data. $\sigma^2$ = støy i data (kan ikke reduseres).

# M07: K-fold kryssvalidering

**Problem:** Ett enkelt train/test-split kan gi tilfeldige resultater

**Løsning: K-fold Cross-Validation**

1. Del data i $k$ like store deler ("folds")
2. For hver fold: bruk den som test, resten som trening
3. Gjennomsnitt av alle $k$ evalueringer




**Fordeler:** Mer robust estimat, bruker all data for både trening og testing

# M08: Baseline-modell

**Hva er en baseline?**

En **enkel referansemodell** som vår ML-modell må slå for å være nyttig.

**Eksempler på baselines:**

- **Klassifisering:** Prediker alltid majoritetsklassen
  - Datasett med 90% friske, 10% syke → baseline accuracy = 90%
- **Regresjon:** Prediker alltid gjennomsnittsverdien
- **Tidsserie:** Bruk forrige verdi som prediksjon

**Hvorfor viktig?**

90% accuracy høres imponerende ut, men ikke hvis baseline er 90%! Viser om ML tilfører **faktisk verdi**. Avslører ubalanserte datasett.

# M09: Klassifisering vs. Regresjon

**Klassifisering:**

- Predikerer **kategorier/klasser**
- Diskrete utfall
- Eksempler:
  - Syk / Frisk
  - Kreft type A / B / C

**Evalueringsmetrikker:**

- Accuracy, Precision, Recall
- F1-score, AUC-ROC

**Regresjon:**

- Predikerer **kontinuerlige verdier**
- Numeriske utfall
- Eksempler:
  - Blodtrykk
  - Medikamentdosering

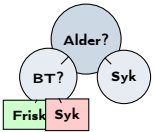
**Evalueringsmetrikker:**

- MSE, RMSE, MAE
- $R^2$ (forklart varians)

# M10: Enkle ML-modeller

**Beslutningstre:**

- Serier av ja/nei-spørsmål
- Lett å tolke
- Kan overtilpasse




**k-Nearest Neighbors:**

- Finn $k$ mest like eksempler
- Majoritetsvotering
- Enkel, men treg



**Logistisk regresjon:**

- Lineær grense
- Gir sannsynligheter
- Rask og tolkbar



**Tips**

Start alltid med enkle modeller før du prøver komplekse!

# Oppsummering: M01–M10

**Nøkkelkonsepter:**

- ML lærer fra data
- Supervised / Unsupervised / Semi-supervised
- Features (X), Labels (y)
- Trening / test / validering
- Over-/undertilpasning

**Beste praksis:**

- Kryssvalidering
- Sammenlign med baseline
- Klassifisering $\neq$ Regresjon
- Start enkelt
- Bias-varians-balanse

**Fremtid: ML + GenAI**

- LLM-agenter for dataanalyse
- Multimodale modeller (tekst+bilde)
- RAG + kliniske retningslinjer
- Automatisert ML-pipeline
- Human-in-the-loop AI

**Medisinsk relevans – ML-anvendelser i helse, medisin og bioteknologi**

**Diagnostikk:** Bildediagnostikk (radiologi, patologi, oftalmologi, dermatologi), biomarkørdeteksjon, EKG/EEG-analyse.
**Prognose:** Overlevelse (OS), progresjonsfri overlevelse (PFS), reinnleggelse, mortalitetsrisiko, sykdomsprogresjon.
**Terapi:** Terapivalg, doseoptimalisering, behandlingsrespons, stråleplanlegging, kirurgisk navigasjon.
**Legemiddel:** Drugability, målidentifikasjon, ADMET-prediksjon, virtual screening, de novo molekyldesign.
**Helsesystem:** Ressursallokering, kapasitetsplanlegging, triagering, ventelisteoptimering, utbruddsdeteksjon.
**Genomikk/biotek:** Variantklassifisering, genekspresjon, proteinstruktur (AlphaFold), single-cell, CRISPR off-target.
**Psykiatri/nevrologi:** Stemningsanalyse, talemarkører, nevrodegenerasjon, anfallsprediksjon.
**Folkehelse:** Epidemiologisk modellering, vaksinestrategi, sosiale determinanter, helseøkonomi (QALY/DALY).

Human-in-the-loop: **Pasientbilde** → **ML: "mulig malign" (87%)** → **Radiolog vurderer** → **Bekrefter/avviser** → **Feedback** → **Modell forbedres**